

Module Machine learning 2025-2026

NICOLAS LE HIR

nicolas.lehir@epitech.eu

TABLE DES MATIÈRES

1	Organisation résumée	2
2	Plan détaillé	2
2.1	Jour 1	2
2.1.1	Introduction au ML et aux différents paradigmes d'apprentissage.	2
2.1.2	Apprentissage, ensemble d'entraînement et de test, régression linéaire, régression polynomale	2
2.1.3	Prérequis techniques : probabilités, statistiques, métriques, librairies	2
2.1.4	Présentation du projet.	2
2.2	Jour 2	2
2.2.1	Gradients	2
2.2.2	Réseaux de neurones	2
2.2.3	Régularisation	3
2.2.4	Scoring	3
2.2.5	Discussion sur le projet	3
2.3	Jour 3	3
2.3.1	Classification, régression logistique.	3
2.3.2	Clustering	3
2.3.3	Hyperparamètres	3
2.3.4	Arbres de classification et de régression, méthodes ensemblistes.	3
2.4	Jour 4	3
2.4.1	Soutenance intermédiaire	3
2.5	Jour 5	3
2.5.1	Feature selection	3
2.5.2	Risques réels et empiriques (apprentissage statistique)	4
2.5.3	Simplicity bias des réseaux de neurones	4
2.5.4	Réduction de dimension	4
2.6	Jour 6	4
2.6.1	Soutenance finale	4

Jour	contenu
1 (2.1)	cours + présentation du projet
2 (2.3)	cours + début projet
3 (2.2)	cours
4	soutenance intermédiaire
5 (2.5)	cours
6	soutenance

TABLE 1 – Proposition d’organisation des journées

1 ORGANISATION RÉSUMÉE

2 PLAN DÉTAILLÉ

2.1 Jour 1

2.1.1 Introduction au ML et aux différents paradigmes d’apprentissage.

Introduction des problématiques liées au ML et des trois principaux paradigmes historiques : apprentissage supervisé, apprentissage non supervisé, apprentissage par renforcement. Discussion sur les autres paradigmes existant, importants aujourd’hui (apprentissage auto-supervisé).

2.1.2 Apprentissage, ensemble d’entraînement et de test, régression linéaire, régression polynomiale

Notion d’entraînement (apprentissage de paramètres), de risque empirique et de surapprentissage. Illustration sur des exemples et discussion sur l’origine du problème : le nombre de données disponibles est fini. Présentation de la régression linéaire et de la régression polynomiale pour illustrer le problème.

2.1.3 Prérequis techniques : probabilités, statistiques, métriques, librairies

Présentation des briques techniques nécessaires au ML. Exercices pour s’entraîner à les manipuler et identifier les notions qui posent problème. Notion de logit.

2.1.4 Présentation du projet.

Présentation des différentes parties et des objectifs.

2.2 Jour 2

2.2.1 Gradients

Les algorithmes d’optimisation par descente de gradient sont omniprésents en ML. Explication de la raison de cette prédominance et du fonctionnement de ces algorithmes. Application sur des exemples simples.

2.2.2 Réseaux de neurones

Les réseaux de neurones sont depuis une vingtaine d’années les types d’estimateurs les plus performants pour de nombreux problèmes ML en haute dimension (vision artificielle, NLP, LLMs). Présentation des NN, entraînement de NN simples et exemple d’un réseau deep learning sur MNIST.

A confirmer : introduction aux réseaux récurrents, aux transformers et LLM.

2.2.3 Régularisation

Souvent, l'apprentissage est modifié afin de contraindre certaines propriétés du modèle obtenu (réduction du surapprentissage, sparsité). Exemple avec la régression Ridge et l'équivalent en réseaux de neurones (weight decay).

2.2.4 Scoring

Etant donné un problème de ML, il existe plusieurs scores pour évaluer la qualité d'un estimateur. Il est important de bien connaître les différents scores les plus utilisés en ML et souvent utile de calculer plusieurs scores, notamment en classification.

2.2.5 Discussion sur le projet

Les étudiants avancent sur le projet et je réponds à leur questions éventuelles.

2.3 Jour 3

2.3.1 Classification, régression logistique.

Présentation de la classification binaire et du problème d'optimisation associé. Exercice d'application de la régression logistique avec scikit-learn sur plusieurs datasets.

2.3.2 Clustering

Introduction au problème du clustering et présentation de différents algorithmes (k-means, clustering hiérarchique, spectral clustering). Discussion sur les hyperparamètres et le choix de l'algorithme.

2.3.3 Hyperparamètres

Les hyperparamètres sont des paramètres des algorithmes choisis manuellement, par opposition aux paramètres appris par optimisation. Ces paramètres sont d'une importance capitale et il existe plusieurs méthodes importantes pour les choisir.

2.3.4 Arbres de classification et de régression, méthodes ensemblistes.

Les arbres de classification et de régression sont une brique de base pour les méthodes ensemblistes les plus utilisées aujourd'hui (Random Forest, Gradient Tree Boosting), qui sont des méthodes atteignant des performances optimales sur de nombreux problèmes.

2.4 Jour 4

2.4.1 Soutenance intermédiaire

2.5 Jour 5

2.5.1 Feature selection

Pour de nombreux problèmes d'apprentissage supervisé, le prétraitement et la sélection des features dans l'espace d'entrée sont aussi importants que le choix de l'estimateur. Il existe de nombreuses techniques de sélection de features, basées sur des considérations statistiques ou sur un apprentissage séquentiels de plusieurs estimateurs.

2.5.2 *Risques réels et empiriques (apprentissage statistique)*

La notion de risque réel et de risque empirique est très importante pour une compréhension profonde du problème du surapprentissage (overfitting) en ML. Présentation de quelques notions théoriques associées à ces notions de risques et discussion sur le compromis biais-variance.

2.5.3 *Simplicity bias des réseaux de neurones*

Les réseaux de neurones semblent ne pas toujours suivre le comportement que l'on pourrait attendre, étant donné leur nombre très élevé de paramètres : ils ont une tendance à ne pas surapprendre, s'ils sont correctement entraînés. Observation de ce phénomène sur un cas simple.

2.5.4 *Réduction de dimension*

La réduction de dimension a de nombreuses applications en ML, du prétraitement de données en vue d'un apprentissage supervisé à la compression. Présentation de la PCA (réduction de dimension linéaire) et exemples de techniques non linéaires.

2.6 Jour 6

2.6.1 *Soutenance finale*